

Direct Heat2D

Report Analisi: Soluzione dell'Equazione di Laplace 2D tramite PINN e NN

1. Definizione del Problema

L'obiettivo è risolvere un problema di conduzione di calore stazionaria in un dominio quadrato con condizioni al contorno miste (Dirichlet), confrontando approcci puramente data-driven (Neural Networks standard) e Physics-Informed (PINN).

Setup Matematico

Equazione Governante (Laplace):

$$\nabla^2 T = \frac{\partial^2 T}{\partial x^2} + \frac{\partial^2 T}{\partial y^2} = 0$$

Condizioni al Contorno (Dirichlet):

- $T(x, 0) = 0$ (Inferiore), $T(x, Ly) = 0$ (Superiore)
- $T(0, y) = 0$ (Sinistro), $T(Lx, y) = 1$ (Destro)

Soluzione Analitica di Riferimento:

Per la validazione è stata utilizzata la soluzione esatta in serie, troncata ai primi $N = 50$ termini:

$$T(x, y) = \sum_{n=1,3,5,\dots}^{\infty} \frac{4}{n\pi} \frac{\sinh(\lambda_n x)}{\sinh(\lambda_n L_x)} \sin(\lambda_n y), \quad \lambda_n = \frac{n\pi}{L_y}$$

2. Metodologia e Discretizzazione

Sono stati confrontati diversi approcci di training variando la distribuzione dei punti e l'inclusione della fisica.

Configurazione dei Dataset

- Punti Dati (NN Random):** 1600 punti interni (Random) + 400 punti di bordo.
- Punti Dati (NN Grid):** 1600 punti interni (Griglia 40×40) + 400 punti di bordo.
- Punti Fisica (PINN Pure):** 1600 punti di collocazione (Griglia 40×40).
- Punti Dati (PINN Data+Phys):** 1000 punti (Subset Random) per supervisione dati + 1600 punti (Griglia) per fisica.
- Boundary:** 400 punti totali equidistanti (100 per lato).

- **Griglia di Validazione:** $50 \times 50 = 2500$ punti.

Definizione della Loss Function

La funzione di costo totale è una somma pesata delle componenti, tutte **normalizzate** sul numero di punti (N) del rispettivo set:

$$\mathcal{L}_{total} = \lambda_{data}\mathcal{L}_{data} + \lambda_{bc}\mathcal{L}_{BC} + \lambda_{physics}\mathcal{L}_{physics}$$

- $\mathcal{L}_{physics}$: Mean Squared Error (MSE) del residuo dell'equazione di Laplace sui punti di collocazione.
- $\mathcal{L}_{BC}$: MSE tra la predizione e il valore imposto al bordo.
- $\mathcal{L}_{data}$: MSE tra predizione e dati osservati (ove presenti).

3. Metriche di Validazione

Per valutare la bontà del modello rispetto alla soluzione analitica:

1. **L2 Relative Error (Errore Globale):**

$$Error_{L2} = \frac{\|T_{pred} - T_{true}\|_2}{\|T_{true}\|_2} = \sqrt{\frac{\sum_{i=1}^N (T_{pred}(i) - T_{true}(i))^2}{\sum_{i=1}^N (T_{true}(i))^2}}$$

2. **Max Relative Error Peak (Errore Puntuale Massimo):**

Indica la peggiore deviazione percentuale. Per evitare singolarità numeriche dove $T \approx 0$, è applicata una maschera $M = \{i \mid |T_{true}(i)| > 0.01\}$:

$$PeakRel\% = \max_{i \in M} \left(\frac{|T_{pred}(i) - T_{true}(i)|}{|T_{true}(i)|} \right) \times 100$$

4. Analisi dei Risultati

4.1 Ottimizzazione Architetture (Phase 1)

Top5 per L2 e max error

Run Type	Architettura	Attivazione	Epoche	Scheduler	L2 Error ()	Picco Max	Loss Totale
NN_Random	6x80	Tanh	40000	Constant	0.0054	11.75	7.8006


Run Type	Architettura	Attivazione	Epoche	Scheduler	L2 Error ()	Picco Max	Loss Totale
NN_Grid	6x80	GELU	40000	Constant	0.0062	6.71	9.3606
NN_Grid	6x80	Tanh	40000	Constant	0.0078	11.71	1.3405
NN_Grid	6x80	Tanh	40000	Decay	0.0079	12.44	7.7906
NN_Random	6x80	Tanh	40000	Decay	0.0085	18.65	9.9406

Run Type	Architettura	Attivazione	Epoche	Scheduler	Picco Max ()	L2 Error	Loss Totale
NN_Random	6x80	SiLU	20000	Constant	5.86	0.0096	2.1705
NN_Grid	6x80	GELU	40000	Constant	6.71	0.0062	9.3606
NN_Random	6x80	SiLU	40000	Constant	9.15	0.0106	2.5205
NN_Grid	4x50	Tanh	40000	Constant	9.86	0.0123	1.3705
NN_Grid	4x50	Tanh	40000	Decay	10.70	0.0088	1.4605

Architettura, epoche, scheduler

Cambiamento (Configurazione)	Miglioramento L2 Medio	Miglioramento Picco Max	Analisi Rapida
Epoche: 20k → 40k	+22.1%	+29.0%	È il fattore più impattante. Raddoppiare il training paga quasi sempre.
Architettura: 4x50 → 6x80	+8.8%	-21.5%	Migliora la precisione media, ma peggiora drasticamente la stabilità sui picchi.
Scheduler: Constant → Decay	+2.9%	+11.7%	Aiuta poco sulla media, ma è ottimo per "limare" i picchi di errore estremi.

Run Type - Activation




Osservazioni

- **Training Time:** L'aumento delle epoche da 20k a 40k ha portato al miglioramento più netto (+22% su L2).
- **Attivazioni:** La **Tanh** si dimostra robusta per minimizzare l'errore medio (L2), mentre **GELU** ha mostrato un miglior controllo sui picchi massimi di errore.
- **Scheduler:** L'uso di un Decay Scheduler ha ridotto i picchi di errore (+11.7% improvement), "limando" le instabilità locali.

4.2 Analisi in Regime di Dati Ridotti (Phase 2)

Si è testata la robustezza riducendo drasticamente il numero di punti di training (da 2000 a 500).

- I modelli **NN Random** mantengono performance superiori rispetto ai modelli su griglia (NN Grid) quando i dati sono scarsi.
- L'approccio Physics-Informed (PINN) inizia a mostrare utilità relativa quando il dataset supervisionato scende sotto soglie critiche, fungendo da regolarizzatore.




4.3 Bilanciamento delle Loss (Phase 3)

È stato identificato che la Loss al Bordo ($\mathcal{L}_{BC}$) tende a dominare il gradiente rispetto alla Loss Fisica. È stato testato un weighting statico:


- $\lambda_{BC} = 1, \lambda_{Phys} = 10, \lambda_{Data} = 50$.

Nonostante il weighting, i risultati preliminari mostrano instabilità o miglioramenti marginali, suggerendo che pesi statici potrebbero non essere sufficienti e che sia necessario investigare algoritmi di pesatura dinamica per bilanciare l'apprendimento tra interno e bordo durante le varie fasi del training.

Overview Loss Pesate:



Dettaglio Training:



5. Conclusioni e Sviluppi Futuri

1. **Architettura:** La configurazione 6x80 con Tanh si conferma la baseline più solida per questo problema stazionario.

2. **Campionamento:** Il campionamento Random (Monte Carlo) performa meglio della griglia fissa per la generalizzazione.
3. **Fisica vs Dati:** Le PINN attuali faticano a battere una NN pura in regime di "tanti dati", ma diventano cruciali in scenari di scarsità di dati (regime *under-determined*).
4. **Prossimi Step:** Implementazione di **Adaptive Loss Weighting** per risolvere il conflitto tra Boundary Loss e Physics Loss, che attualmente limita la convergenza della componente fisica.